

Arquitectura de Computadores

Unidad 11: Procesadores Gráficos (GPU) y Arquitecturas Avanzadas

Post-Contenido 2

Ingeniería de Sistemas
2026

Objetivo de la Actividad

El estudiante elabora un análisis comparativo técnico de los principales aceleradores de hardware para cargas de trabajo de inteligencia artificial (GPU, TPU, NPU y FPGA), evaluando sus diferencias arquitectónicas, rendimiento en benchmarks MLPerf, eficiencia energética y escenarios de aplicación óptimos, con el fin de formular una recomendación fundamentada para casos de uso específicos.

Prerrequisitos

Para desarrollar este análisis, el estudiante debe haber estudiado la Guía de Contenido de la Unidad 11 (secciones 5 y 6) y contar con acceso a fuentes técnicas confiables:

- Informe MLPerf Inference v4.1 (MLCommons, 2024) — disponible en mlcommons.org/benchmarks
- Hojas de especificaciones técnicas oficiales de: NVIDIA H100/A100, Google TPU v4/v5, Apple M3 Ultra, Qualcomm Snapdragon 8 Gen 3
- Acceso a Google Scholar o IEEE Xplore para artículos de investigación
- Dominio de conceptos: TFLOPS, TOPS, TDP, latencia de inferencia, batch size, precision (FP32/FP16/BF16/INT8)

Desarrollo del Análisis Comparativo

Parte 1: Caracterización de Cada Acelerador

El documento analiza cuatro categorías de aceleradores. Para cada uno, el estudiante describe su arquitectura interna (unidad de cómputo fundamental, tipos de dato soportados, jerarquía de memoria) y su modelo de programación:

Acelerador	Paradigma	Unidad Cómputo	Modelo de Programación	Caso de Uso Primario
GPU (NVIDIA H100)	SIMT masivo	CUDA Core + Tensor Core	CUDA / cuDNN / TensorRT	Entrenamiento DNN, HPC
TPU v5 (Google)	Systolic Array	MXU 128×128 BF16	XLA / JAX / TensorFlow	Inferencia/entrenamiento LLM
NPU (Apple M3)	Dataflow fijo	Neural Engine 18-core	Core ML / BNNS	Inferencia on-device <5W

Acelerador	Paradigma	Unidad Cómputo	Modelo de Programación	Caso de Uso Primario
FPGA (Xilinx Alveo)	Reconfigurable	LUT + DSP + BRAM	HLS (Vitis) / VHDL/Verilog	Inferencia latencia < 1ms

Parte 2: Benchmarks MLPerf

MLPerf Inference es el benchmark estándar de la industria para comparar aceleradores en tareas de IA reales. El estudiante consulta los resultados públicos de MLPerf v4.1 para los siguientes modelos y completa una tabla comparativa con datos reales:

- ResNet-50 v1.5 (clasificación de imágenes, 224×224): throughput en muestras/segundo
- BERT-Large (procesamiento de lenguaje natural, SQuAD v1.1): latencias p99 en ms
- Stable Diffusion XL (generación de imágenes): muestras/segundo

Para cada modelo, el análisis identifica qué acelerador lidera en throughput y cuál lidera en eficiencia energética (muestras/segundo/watio), argumentando las razones arquitectónicas.

Checkpoint de Verificación

Checkpoint 1: La sección de caracterización incluye la tabla comparativa con datos técnicos reales (no estimados) y cita las fuentes para cada especificación. La sección de benchmarks MLPerf presenta datos numéricos reales del informe oficial v3.1 o v4.1.

Parte 3: Análisis Costo-Rendimiento y TCO

El rendimiento bruto en TOPS no es suficiente para tomar decisiones de arquitectura en producción. El análisis incorpora tres dimensiones adicionales: (1) Costo de adquisición: NVIDIA H100 SXM (~\$30,000 USD), TPU v4 Pod (solo disponible vía Google Cloud, ~\$32/hora), FPGA Alveo U55C (~\$8,000 USD), Apple M3 Ultra Mac Studio (~\$4,000 USD). (2) Consumo energético (TDP): determina el costo operativo a largo plazo y las restricciones de densidad en el datacenter. (3) Total Cost of Ownership (TCO) a 3 años: combinando adquisición, energía y costos de desarrollo/mantenimiento del software.

El documento elabora un análisis de TCO simplificado para dos escenarios: (a) startups de IA con inferencia en la nube a escala media (< 100 req/s), y (b) empresas con inferencia en edge/dispositivo (smartphone, cámara industrial, vehículo autónomo).

Checkpoint de Verificación

Checkpoint 2: La sección de costo-rendimiento incluye precios reales consultados

y un cálculo de TCO aproximado para los dos escenarios indicados. El análisis argumenta cuál acelerador es más adecuado para cada escenario con fundamento técnico-económico.

Parte 4: Recomendación Fundamentada

El documento concluye con una recomendación estructurada para tres perfiles distintos de organización. Para cada perfil, el estudiante selecciona el acelerador óptimo, justifica la decisión con al menos 3 criterios técnicos del análisis previo y menciona las limitaciones de la elección:

- Perfil A: Laboratorio de investigación universitario con presupuesto de \$10,000 USD y necesidad de experimentar con modelos de visión y NLP (tamaño hasta 7B parámetros).
- Perfil B: Empresa de manufactura que requiere inspección visual en tiempo real (< 5 ms latencia) en 50 líneas de producción con cámaras industriales.
- Perfil C: Proveedor de servicios cloud que entrena modelos de lenguaje de 70B parámetros en clústeres de 512 aceleradores con comunicación colectiva intensiva.

Checkpoint de Verificación

Checkpoint 3: La sección de recomendación aborda los tres perfiles con justificaciones técnicas claras, reconoce las limitaciones de cada elección y cita fuentes que respaldan la recomendación.

El documento tiene estructura completa: introducción, cuatro secciones de análisis, conclusiones y referencias en formato APA.

Rúbrica de Evaluación

Criterio	Excelente (90-100%)	Bueno (70-89%)	Aceptable (50-69%)	Insuficiente (0-49%)
Contenido y Análisis (40%)	El análisis comparativo es técnicamente preciso, usa datos reales de MLPerf/anunciados por fabricantes, distingue correctamente los perfiles de carga donde cada acelerador es óptimo.	El análisis es correcto en sus puntos principales pero le falta profundidad en alguna dimensión (ej.: analiza rendimiento pero no costo-eficiencia energética).	El análisis es superficial o tiene imprecisiones técnicas menores que no invalidan la argumentación general.	El análisis es incorrecto, confunde características técnicas fundamentales, o está ausente en secciones requeridas.
Aplicación Práctica (30%)	Los casos de uso están respaldados por ejemplos reales (empresas,	Los casos de uso son pertinentes y correctos, aunque algunos son	Los casos de uso son vagamente relacionados o la conexión con el	Los casos de uso son incorrectos, irrelevantes o están ausentes.

Criterio	Excelente (90-100%)	Bueno (70-89%)	Aceptable (50-69%)	Insuficiente (0-49%)
Estructura y Presentación (20%)	modelos específicos, benchmarks públicos) y la recomendación final es coherente con el análisis. El documento tiene estructura clara (introducción, análisis por criterio, tabla comparativa, conclusiones), terminología técnica precisa y redacción en tercera persona.	genéricos o podrían estar mejor fundamentados con datos. El documento está bien organizado en su mayor parte con terminología mayormente correcta; puede mejorar la redacción en algunas secciones.	análisis técnico no es siempre clara. El documento tiene una estructura básica pero es inconsistente en la organización o en el nivel de detalle entre secciones.	El documento carece de estructura o la terminología técnica es sistemáticamente incorrecta.
Referencias (10%)	Cita mínimo 3 fuentes técnicas recientes (2020 o posterior) en formato APA, incluyendo al menos una publicación académica o informe técnico oficial.	Cita 2 fuentes pertinentes en formato APA aproximado; las fuentes son relevantes aunque no siempre las más autorizadas.	Cita 1 fuente o las fuentes no siguen formato APA; la calidad de las fuentes es insuficiente (p. ej., solo Wikipedia).	No cita fuentes o las referencias son inexistentes.

Entregables

Elemento	Especificación
Formato	Documento PDF
Nombre del archivo	Apellido_Post2_U11.pdf
Contenido	Análisis comparativo con introducción, secciones por criterio, tabla comparativa y conclusiones
Extensión	Mínimo 4 páginas, máximo 8 páginas (excluyendo portada y referencias)
Referencias	Mínimo 3 fuentes técnicas recientes (2020 o posterior) en formato APA